Universidad de Guadalajara

Ingeniería en Computación

Compiladores

Practica 1 – Analizador Léxico

28-FEBRERO-2025

Roberto Carlos Rodríguez Rivas

En esta práctica nos encargaremos de desarrollar un programa en Python que se encargue de realizar un análisis léxico de diferentes cadenas para poder corroborar que las cadenas que introduzcamos sean permitidas en el lenguaje que el maestro previamente y definió. Esta actividad será la primera de 4 practicas, para poder crear un compilador funcional al final del curso.

Explicación del código

En el desarrollo del código decidí utilizar una librería llamada ‘***collections’*** para que me permitiera crear un diccionario que devuelve un valor por defecto si una clave no existe. Decidí trabajar con una clase llamada ‘***lexer’*** que tendrá el será nuestro analizador léxico, dentro de la clase defino una lista de tokens con sus respectivas expresiones regulares y a cada token le asigno un numero para identificar su tipo (un diccionario). Creo también 1 diccionario para contar cuantas veces aparece cada tipo de token, creo dos listas, la primera para almacenar los errores léxicos encontrados y la segunda para almacenar los tokens reconocidos junto con su tipo.

Creo una función llamada ‘***analize’*** que se encargará de la cadena de entrada y extraerá los tokens. Dentro de la función me encargo de recorrer los caracteres que analizaré, siempre ignorando los espacios. Si encuentro un match en la posición actual con ayuda del regex, extraigo el token, lo guardo en la lista de coincidencias e incremento el contador de este tipo de token, muevo la posición hacia delante según el tamaño del de token encontrado, marcamos que encontramos un token y salimos del bucle. En el caso de no encontrar ningún token valido en la posición actual lo consideramos un error léxico y seguimos analizando el siguiente.

Código fuente con comentarios:

```
# Importamos la librería 're' para trabajar con expresiones regulares
import re

# Importamos 'defaultdict' de la librería 'collections'
# Nos permite crear un diccionario que devuelve un valor por defecto si una clave
no existe
from collections import defaultdict

# Definimos la clase 'Lexer', que será nuestro analizador léxico
class Lexer:
    def __init__(self):
        """
        Constructor de la clase Lexer.
        Define los tokens a reconocer y crea estructuras para almacenar los
resultados.
        """

        # Lista de tokens con sus respectivas expresiones regulares
        # Cada token tiene un número asociado para identificar su tipo
        self.tokens = [
```

```
            (0, r'\b(int|float|char|void|string)\b'),  # Tipos de datos
            (10, r'\bif\b'),  # Palabra clave "if"
            (11, r'\bwhile\b'),  # Palabra clave "while"
            (12, r'\breturn\b'),  # Palabra clave "return"
            (13, r'\belse\b'),  # Palabra clave "else"
            (14, r'\bfor\b'),  # Palabra clave "for"
            (2, r'\b\d+(\.\d+)?\b|\bpi\b|#'),  # Constantes numéricas y la
constante 'pi'
            (1, r'\b[a-zA-Z_][a-zA-Z0-9_]*\b'),  # Identificadores (variables,
nombres de funciones)
            (3, r';'),  # Punto y coma (;)
            (4, r','),  # Coma (,)
            (5, r'\('),  # Paréntesis izquierdo '('
            (6, r'\)'),  # Paréntesis derecho ')'
            (7, r'\{'),  # Llave izquierda '{'
            (8, r'\}'),  # Llave derecha '}'
            (9, r'='),  # Operador de asignación '='
            (15, r'[\+\-]'),  # Operadores aritméticos de suma/resta ('+', '-')
            (16, r'[\*/<>]{1,2}'),  # Operadores multiplicativos y relacionales
('*', '/', '<', '>')
            (17, r'&&|\|\|'),  # Operadores lógicos ('&&', '||')
            (18, r'[<>]=?|==|!='),  # Operadores relacionales ('<', '>', '>=',
'<=', '==', '!=')
            (19, r'\$'),  # Símbolo especial ('$')
        ]

        # Diccionario para contar cuántas veces aparece cada tipo de token
        self.token_counts = defaultdict(int)

        # Lista para almacenar los errores léxicos encontrados
        self.errors = []

        # Lista donde almacenaremos los tokens reconocidos junto con su tipo
        self.matches = []

    def analyze(self, input_string):
        """
        Analiza una cadena de entrada y extrae los tokens.

        """
        pos = 0

        # Recorremos toda la cadena mientras queden caracteres por analizar
        while pos < len(input_string):
            # Ignoramos los espacios en blanco y tabulaciones
```

```
            if input_string[pos].isspace():
                pos += 1
                continue

            match_found = False  # Variable para saber si encontramos un token
válido en esta posición

            # Recorremos la lista de tokens definidos para intentar hacer una
coincidencia
            for token_type, patron in self.tokens:
                regex = re.compile(patron)  # Compilamos la expresión regular
                match = regex.match(input_string, pos)  # Intentamos encontrar un
match en la posición actual

                # Si encontramos un token válido
                if match:
                    lexeme = match.group(0)  # Extraemos el texto del token
                    self.matches.append((lexeme, token_type))  # Guardamos el
token en la lista de coincidencias
                    self.token_counts[token_type] += 1  # Incrementamos el
contador de este tipo de token
                    pos += len(lexeme)  # Movemos la posición hacia adelante
según el tamaño del token encontrado
                    match_found = True  # Marcamos que encontramos un token
                    break  # Salimos del bucle porque ya encontramos un token en
esta posición

            # Si no encontramos ningún token válido en la posición actual, lo
consideramos un error léxico
            if not match_found:
                self.errors.append(f"Error léxico en posición {pos}:
'{input_string[pos]}'")
                pos += 1  # Avanzamos al siguiente carácter para seguir
analizando

    def display_results(self):
        """
        Muestra los resultados del análisis léxico: tokens encontrados, conteo
por categoría y errores.
        """
        print("\nTokens encontrados:")
        # Mostramos todos los tokens encontrados junto con su tipo
        for lexeme, token_type in self.matches:
            print(f"{lexeme} -> {token_type}")
```

```
        print("\nCantidad de tokens por categoría:")
        # Mostramos cuántos tokens de cada tipo fueron encontrados
        for token_type, count in sorted(self.token_counts.items()):
            print(f"Categoría {token_type}: {count}")

        # Si hubo errores léxicos, los mostramos
        if self.errors:
            print("\nErrores encontrados:")
            for error in self.errors:
                print(error)

# Bloque principal: solo se ejecuta si el script es ejecutado directamente
if __name__ == "__main__":
    input_string = input("Ingrese el código a analizar: ")  # Pedimos al usuario
que ingrese código fuente
    lexer = Lexer()  # Creamos una instancia del analizador léxico
    lexer.analyze(input_string)  # Analizamos la entrada del usuario
    lexer.display_results()  # Mostramos los resultados del análisis
```

Ejemplos de ejecución con capturas de pantalla.

- **int x = 10; float y = 3.14;**

```
Ingrese el código a analizar: int x = 10; float y = 3.14;

Tokens encontrados:
int -> 0
x -> 1
= -> 9
10 -> 2
; -> 3
float -> 0
y -> 1
= -> 9
3.14 -> 2
; -> 3

Cantidad de tokens por categoría:
Categoría 0: 2
Categoría 1: 2
Categoría 2: 2
Categoría 3: 2
Categoría 9: 2
```

- **if (x > 0) { return x; }**

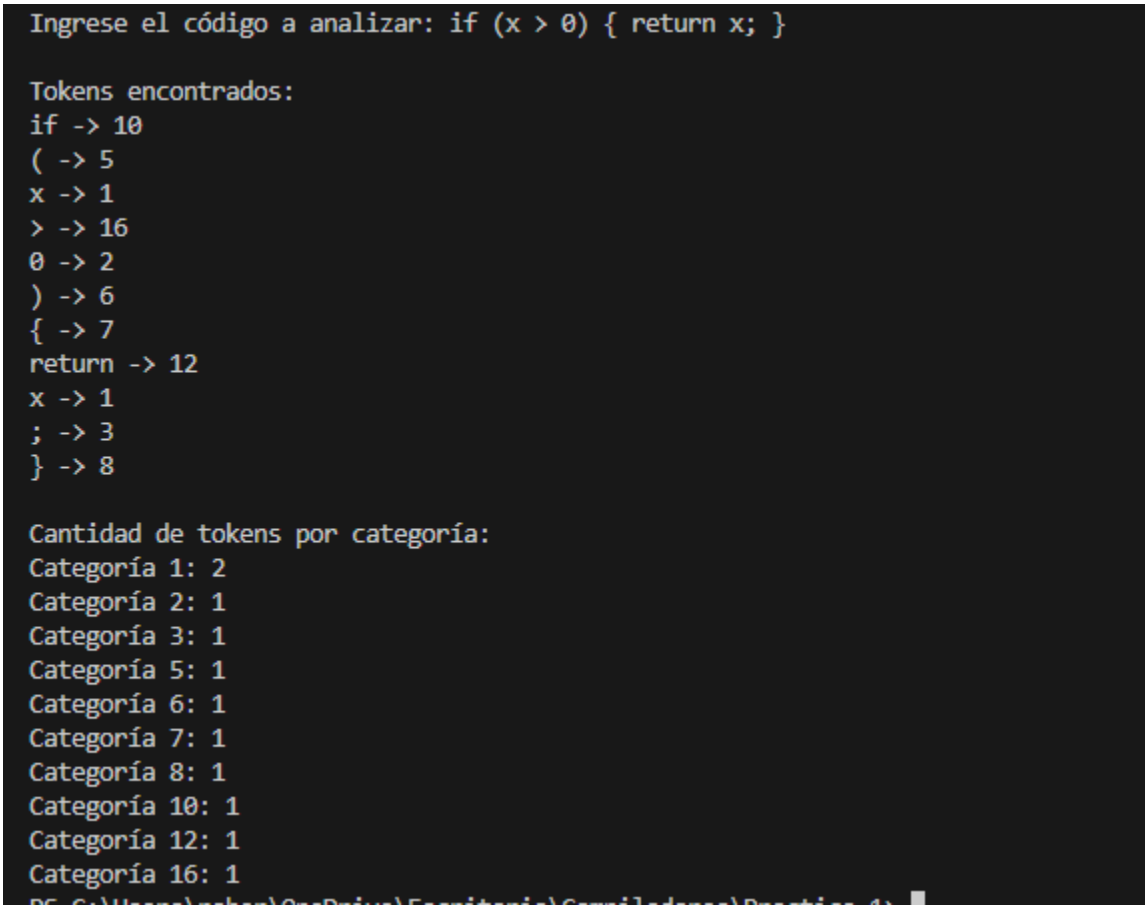

- **while (x < 5) { x = x + 1; }**

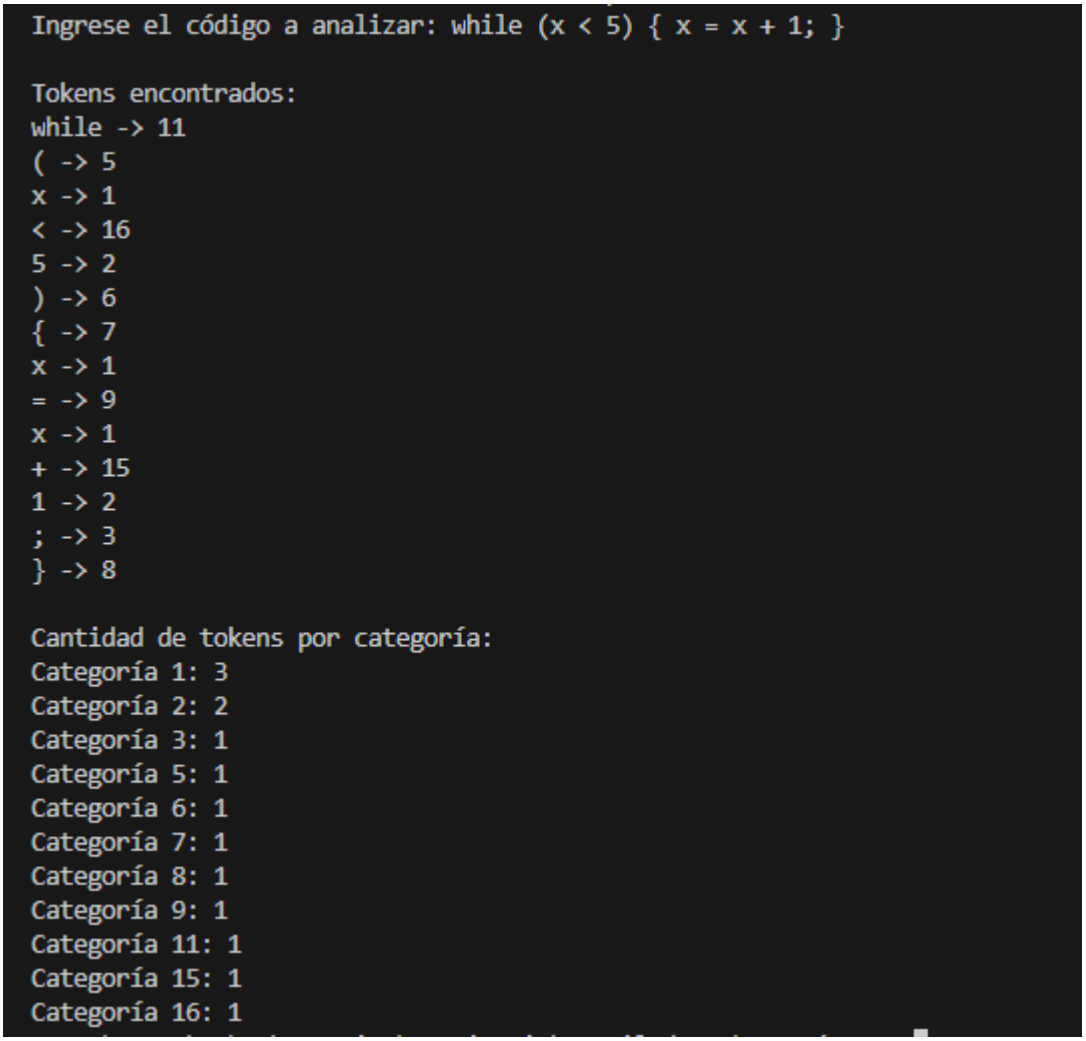
Ingrese el código a analizar: while (x < 5) { x = x + 1; }
Tokens encontrados:
while -> 11
(-> 5
x -> 1
< -> 16
5 -> 2
) -> 6
{ -> 7
x -> 1
= -> 9
x -> 1
+ -> 15
1 -> 2
; -> 3
} -> 8
Cantidad de tokens por categoría:
Categoría 1: 3
Categoría 2: 2
Categoría 3: 1
Categoría 5: 1
Categoría 6: 1
Categoría 7: 1
Categoría 8: 1
Categoría 9: 1
Categoría 11: 1
Categoría 15: 1
Categoría 16: 1

- **int x = 10$;**

```
Ingrese el código a analizar: int x = 10$;

Tokens encontrados:
int -> 0
x -> 1
= -> 9
10 -> 2
$ -> 19
; -> 3

Cantidad de tokens por categoría:
Categoría 0: 1
Categoría 1: 1
Categoría 2: 1
Categoría 3: 1
Categoría 9: 1
Categoría 19: 1
```

- **if (a == b && c != d) { x = y || z; }**

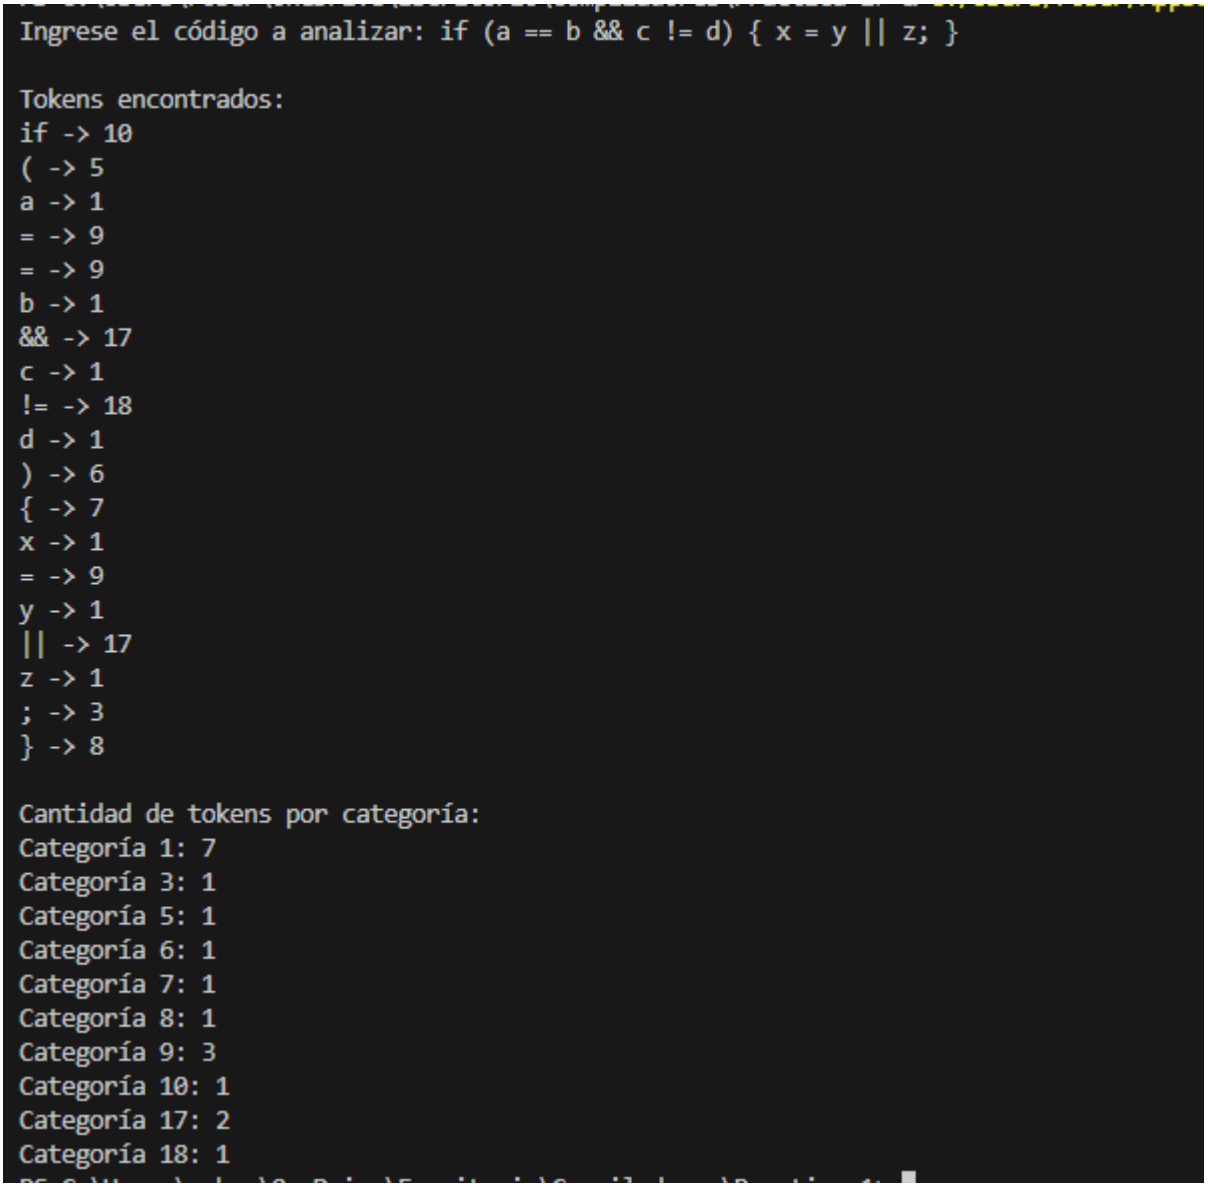
Ingrese el código a analizar: if (a == b && c != d) { x = y || z; }
Tokens encontrados:
if -> 10
(-> 5
a -> 1
= -> 9
= -> 9
b -> 1
&& -> 17
c -> 1
!= -> 18
d -> 1
) -> 6
{ -> 7
x -> 1
= -> 9
y -> 1
|| -> 17
z -> 1
; -> 3
} -> 8
Cantidad de tokens por categoría:
Categoría 1: 7
Categoría 3: 1
Categoría 5: 1
Categoría 6: 1
Categoría 7: 1
Categoría 8: 1
Categoría 9: 3
Categoría 10: 1
Categoría 17: 2
Categoría 18: 1

Justifique los resultados obtenidos.

El desarrollo y prueba del analizador léxico permitieron verificar su correcto funcionamiento en la identificación de tokens y detección de errores. Se confirmó que el analizador reconoce adecuadamente los tipos de datos (int, float, etc.), identificadores (x, variable1), operadores (=, +, -), símbolos (;, {, }) y constantes numéricas, incluyendo flotantes (3.14, 0.5).

Los resultados obtenidos confirman que el analizador cumple su función de convertir una secuencia de caracteres en una lista de tokens y reportar errores léxicos. Este proceso es fundamental en la compilación, ya que proporciona una base estructurada para la siguiente fase del análisis sintáctico.